

附录

正文未报告部分

附录 1 供应链韧性指标测度

附表 1：企业供应链韧性指标体系

一级指标	二级指标	三级指标
供需匹配	供给管理效率	库存调整幅度
	供需匹配精准度	企业生产波动对需求波动的偏离度
供需关系	供需稳定关系	供应链集中度
		供应商关系稳定性
		客户关系稳定性
		总资产净利润率
	供需协同关系	现金及现金等价物周转率
供应创新	企业自主创新	申请专利知识宽度
		授权专利知识宽度
	供应链创新扩散	剔除自引用后的发明专利被引量加 1 取自然对数

具体模型及步骤如下：

假定给定一个输入样本 $\mathbf{x} \in \mathfrak{d}^F$ ，编码器 $\Phi_e(\bullet)$ 将具有 F 维高维特征空间的样本 $\mathbf{x}$ 压缩为具有 f 维低维特征空间的样本 $\mathbf{z} = \Phi_e(\mathbf{x}; \Theta_e)$ ， Θ_e 为深度自编码器所对应的权重参数，自编码器共包含编码器 $\Phi_e(\bullet): \mathfrak{d}^F \mapsto \mathfrak{d}^f$ 和解码器 $\Phi_d(\bullet): \mathfrak{d}^f \rightarrow \mathfrak{d}^F$ 。同时，解码器 $\Phi_d(\bullet)$ 将潜在低维的 $\mathbf{z}$ 进行重构，并映射为与样本 $\mathbf{x}$ 具有相同特征维度的 $\hat{\mathbf{x}} = \Phi_d(\mathbf{z}; \Theta_d)$ 。为了自适应地更新并选择地标中心，利用 Sigma 原则进行地标中心的初步选取，并生成集合 $\mathbf{A}$ ，具体如下：


$$\mathbf{A} = \left\{ z_i \mid \sum_{x_j \in X} \chi(\|x_i - x_j\|_2 - d_c) * \delta_i \geq \mu + \sigma * 2, \forall z_i \in Z \right\} \quad (1)$$

其中， d_c 为截断距离， δ_i 为最小相对距离。需要说明的是 $\mathbf{A}$ 集合中容易存在多个候选地标沉积在同一片高密度聚集区域，造成地标中心冗余，不利于地标中心的稀疏性和代表性。因此，首先为每个地标中心找到其近邻地表中心集合，并进行过滤：

$$N(l_i) = \left(l_j \in A \mid \|x_i - x_j\|_2 < d_c, \forall l_j \in A \right) \quad (2)$$

$$\zeta = \left\{ l_j \in A \mid \max \left(\sum_{x_j \in X} \chi(\|x_i - x_j\|_2 - d_c) \right), \forall l_j \in N(l_i) \right\} \quad (3)$$

解码器输出的正常样本、异常样本和地标中心如下附图 1 所示，可以看出地标中心选取极具稀疏性和代表性，且明显区分开来正常样本和异常样本。在此基础上，本文进一步剔除极端异常值样本，以提升后续分析的代表性和稳健性。



附图 1：潜在特征提取结果

此时，将 4 维的决策矩阵 $\hat{\mathbf{x}} = \begin{bmatrix} x_{11} & x_{12} & x_{13} & x_{14} \\ x_{21} & x_{22} & x_{23} & x_{24} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & x_{n3} & x_{n4} \end{bmatrix}$ 消除量纲，使不同维度的特征在同一

尺度下比较，得到 $r_{ij} = \frac{x_{ij}}{\sqrt{\sum_{i=1}^n x_{ij}^2}}$ 。在得到标准化决策矩阵后，计算加权标准化矩阵 v_{ij} ，得

到 $v_{ij} = w_j \cdot r_{ij}$ ，然后分别计算每个企业到正、负理想解的距离 $S_i^+ = \sqrt{\sum_{j=1}^n (v_{ij} - v_j^+)^2}$ 和

$S_i^- = \sqrt{\sum_{j=1}^n (v_{ij} - v_j^-)^2}$ 。最后，计算第 i 个企业与理想解的相对贴近度 $\delta_i = \frac{S_i^-}{S_i^+ + S_i^-}$ ，从而得到

TOPSIS 评价后的企业供应链韧性 (Res)。

附录 2 数据要素应用能力的文本关键词

企业数据要素广度应用能力相关关键词提取主要体现在以下三个方面：①在数据基础设施层面，考虑企业能否配备完善的软硬件设备与网络系统，以支持数据的生成、采集、传输、存储与处理功能，包括核心计算设备、基础设施节点、网络连接设施、电力与支撑系统以及算力资源等，其部署程度直接反映数据基础设施在不同业务单元中的覆盖水平（钞小静和薛志欣，2023；王海等，2023）；②在数据处理与分析过程中，考虑企业能否广泛采用基础性的数据分析、数据挖掘、可视化、聚类分析等分析工具，体现其基础数据技术的广度应用能力；③在数据管理与存储层面，考虑企业能否具备多样化的数据管理与存储能力，包括对结构化、非结构化及实时数据等多类型数据的采集、组织、分类、访问和存储能力。同时，还需关注其在数据目录、集中式或分布式存储、云存储、对象存储等方面的支撑能力，以保障数据在全组织范围内的持续流通与适配性。

企业数据要素深度应用能力的相关关键词主要从以下两个方面进行提取：①在数据驱动应用层面，关注企业能否在生产运营、营销服务、金融决策等关键业务场景中，实质性部署数据驱动技术与算法模型，使数据嵌入业务流程并产生智能化响应。这类能力既体现为利用“算法优化”“机器学习”“监督学习”“强化学习”“神经网络”“深度学习”“计算机视觉（CV）”“多模态学习”“多任务学习”“集成学习”等技术，高效执行人脸识别、身份识别、语音识别、图像识别等复杂任务，也体现为构建“未来工厂”“数字孪生”“数字供应链”“智慧医疗”“智慧交通”“智慧城市”“量化金融”等数据驱动应用系统，从而提升业务效率和决策水平（孙新波等，2019）；②在数据安全性与隐私层面，关注企业在提升数据要素应用能力的同时，是否同步构建起与之匹配的数据保护与风险防控体系。一方面，通过“数据安全”“数据隐私”“数据脱敏”“数据合规”“数据跨境合规”“隐私合规”“合规认证”“网络安全”“数据泄露”等制度与管理安排强化治理基础；另一方面，通过“加密”“数据备份”“隐私计算”“差分隐私”“同态加密”“可信环境”等技术手段，将安全与隐私保护嵌入数据全生命周期管理过程中，确保数据使用的安全性、合规性与可控性。

附表 2：数据要素应用能力的文本关键词

一级指标	二级指标	关键词（*为辅助性术语）
数据要素广度应用能力 (<i>Breadth</i>)	数据基础设施	主机、服务器、运算设备、终端、一体机、GPU、数据中心、云端、机房、机柜、网络、交换机、电源冗余、散热系统、不间断电源、算力、带宽
	数据处理与分析	并行计算、分布式计算、边缘计算、批处理、流处理、数据传递、数据读取、数据写入、数据处理、数据管道、数据同步、数据共享、数据集成、数据平台、数据中台、分布式架构、数据分析、数据挖掘、可视化、决策树、聚类分析、主成分分析、互联网技术*、信息技术*
	数据管理与存储	数据库、集中式存储、分布式存储、数据湖、云存储、本地存储、对象存储、块存储、多副本存储、EB 级存储、数据管理*、信息管理*、元数据、数据目录
数据要素深度应用能力 (<i>Depth</i>)	数据驱动应用	AI*、智能*、数据驱动*、技术赋能*、算法优化、未来工厂、数字化*、数字孪生、数字供应链、智慧医疗、智慧农业、智慧交通、智慧城市、量化金融、投资决策辅助系统、无人驾驶、机器人、自动化、物联网、机器学习、监督学习、强化学习、神经网络、深度学习、计算机视觉（CV）、多模态学习、多任务学习、集成学习、人脸识别、身份识别、语音识别、图像识别
	数据安全和隐私	数据安全、数据隐私、隐私保护、信息保护、敏感信息、数据脱敏、数据合规、数据跨境合规、差分隐私、隐私合规、合规认证、网络安全、数据泄露、数据备份、加密、隐私计算、可信环境、同态加密

注：表中带“*”号的关键词为语义范畴较为宽泛的辅助性术语，主要用于辅助识别相关候选语句。

附录 3 数据要素应用能力指标的有效性检验

本文进一步对基于文本的企业数据要素应用能力指标的有效性进行检验。借鉴金星晔等（2024）的研究思路，从数据要素产出、时间趋势、行业差异以及地区分布特征四个维度开展检验。

首先，本文检验企业数据要素应用能力是否与数据要素产出之间存在正向关系。为衡量数据要素产出，本文选取关键数字技术专利授权量和人工智能相关专利授权量分别来衡量企业关键数字技术创新（Dig）和人工智能创新（AI）。其原因在于，关键数字技术创新和人工智能创新均高度依赖于数据要素的积累与应用（Cockburn et al., 2019; Eisfeldt et al., 2024; 冯启良等，2025），能够在一定程度上反映企业将数据要素转化为创新产出的能力。回归检验结果如附表 3 中列（1）至列（6）所示，企业数据要素应用能力及其广度和深度维度，均与关键数字技术创新和人工智能创新呈显著正相关。考虑到“学习型”人工智能创新①对数据要素的依赖程度更高，本文进一步识别并提取了“学习型”人工智能相关专利②（learning），以更准确衡量企业数据要素产出。回归检验结果如附表 3 中列（7）至列（9）所示，企业数据要素应用能力及其广度和深度维度仍然与“学习型”人工智能创新显著正相关，进一步验证了两者之间的稳健正向关系。


附表 3 数据要素应用能力指标有效性检验：基于数据要素产出角度

变量	(1) <i>Dig</i>	(2) <i>Dig</i>	(3) <i>Dig</i>	(4) <i>AI</i>	(5) <i>AI</i>	(6) <i>AI</i>	(7) <i>learning</i>	(8) <i>learning</i>	(9) <i>learning</i>
<i>Dea</i>	0.0707*** (0.0141)			0.0723*** (0.0129)			0.0320*** (0.0086)		
<i>Breadth</i>		0.0839*** (0.0129)			0.0847*** (0.0114)			0.0426*** (0.0083)	
<i>Depth</i>			0.0503*** (0.0116)			0.0640*** (0.0117)			0.0380*** (0.0085)
企业固定效应	是	是	是	是	是	是	是	是	是
年份固定效应	是	是	是	是	是	是	是	是	是
样本量	20519	20519	20519	20621	20621	20621	20621	20621	20621
R ²	0.6418	0.6423	0.6414	0.7727	0.7733	0.7726	0.7000	0.7005	0.7004

其次，从时间趋势来看，本文统计企业数据要素应用能力及关键数字技术创新、人工智能创新和“学习型”人工智能创新的年度均值，判断它们变动趋势是否一致。附图 2 显示，企业数据要素应用能力整体呈现稳步上升趋势，而其余三类数据要素产出指标亦持续增长，尽管增速较缓，但趋势一致。整体上，企业数据要素产出与数据要素应用能力的提升呈协同演进特征，说明基于文本的企业数据要素应用能力指标有效。

① 在参考李玉花等（2024）的基础上，本文认为人工智能创新可分为三类技术路径：①“载体型”侧重于材料、结构、封装与硬件平台创新；②“逻辑型”涵盖控制逻辑、电路架构与芯片指令等设计；③“学习型”则聚焦于机器学习、深度学习及相关模型与推理技术。

② 为系统识别人工智能创新的细分类别，本文结合自然语言处理技术、深度学习推理机制与自动化数据处理框架，构建了专利文本的人工智能创新类型分类流程。具体而言，首先基于 Python 环境，批量读取专利中文摘要文本，并利用 DeepSeek-V3 大语言模型的推理能力对专利摘要内容进行语义识别与自动分类。在分类过程中，本文通过构建标准化分类提示词（prompt），结合链式推理机制与低温度（temperature=0.2）控制策略，引导 DeepSeek-V3 模型对专利文本进行精准解析与推理判断。




附图 2 数据要素应用能力指标有效性检验：时间趋势

再次，从行业差异的角度来看，本文分析不同行业的企业数据要素应用能力是否与其行业特征一致。本文将样本企业按照其所属行业代码划分为六类^①，即信息与数字产业、高技术制造业、生活性服务业、生产性服务业、传统制造业，以及低技术/资源类行业。在此基础上，对各行业类别中的企业数据要素应用能力（Dea）进行比较分析。方差分析（ANOVA）及 Bonferroni 多重比较检验结果见附表 4，表明不同行业间企业的数据要素应用能力存在显著差异。图 3 进一步展示了不同行业间企业数据要素应用能力的分布情况。可以看出，信息与数字产业和高技术制造业的企业整体数据要素应用能力显著高于传统制造业和低技术/资源类行业，反映出这些行业在数据技术应用与数据驱动创新方面的领先优势。这一结果印证了本文指标体系的有效性：一方面，数据密集型行业由于对数据处理、算法优化与场景嵌入的高度依赖，天然具备更强的数据要素应用能力；另一方面，传统制造与资源类行业在基础设施、技术集成和数据治理等方面存在短板，因而得分偏低。

附表 4 数据要素应用能力指标有效性检验：基于数据要素产出角度

	信息与数字产业	高技术制造业	生活性服务业	生产性服务业	传统制造业
高技术制造业	-1.4329***				
生活性服务业	-1.6571***	-0.2241***			
生产性服务业	-2.2544***	-0.8214***	-0.5973***		
传统制造业	-3.0088***	-1.5759***	-1.3517***	-0.7545***	
低技术/资源类行业	-3.0849***	-1.6519***	-1.4278***	-0.8305***	-0.0761
ANOVA-F检验	2171.41				
ANOVA-P检验	p < 0.001				
Bartlett's Equal-Variances Test	p < 0.001				

^① 分类依据主要参照企业的《国民经济行业分类（GB/T 4754-2017）》四位代码，并结合行业在数据依赖程度和技术密集度上的特征进行界定。例如，I63、I64 等属于信息传输与互联网服务，被划为“信息与数字产业”；C18、C21 等则为装备与电子制造领域，归为“高技术制造业”；而 A01 - A05、B06 - B11 等资源型行业则归入“低技术/资源类”。



附图 3 数据要素应用能力指标有效性检验：行业差异

附录 4 描述性统计

附表 5 报告了变量的描述性统计结果。可以看出，企业供应链韧性（Res）的均值为 0.0476，整体水平较低，标准差为 0.0151，显示韧性水平的变异性较小且分布较为集中；最小值为 0.0363，接近均值，表明多数企业的韧性水平趋于一致，而最大值达 0.5738，表明少数企业在供应链韧性方面表现出显著优势。数据要素应用能力（Dea）的均值为 3.6396，标准差为 1.6325，反映了样本企业间数据要素应用能力的显著差异，表明企业间存在较大的异质性。数据要素广度应用能力（Breadth）的均值为 2.6827，标准差为 1.7029，较高的离散程度显示企业在不同领域和节点的数据覆盖水平差异显著。数据要素深度应用能力（Depth）的均值为 2.9145，高于数据要素广度应用能力的均值，表明企业更倾向于在单一领域进行深入的数据应用，而非广范围覆盖。标准差为 1.6192，相对较低，反映了企业在数据要素深度应用能力上的水平分布更为集中。整体来看，企业在数据要素应用中更偏向于深度探索，而在广度覆盖上的差异性和不足较为显著。

附表 5：描述性统计

变量符号	变量名称	样本量	均值	标准差	最小值	最大值
<i>Res</i>	企业供应链韧性	21056	0.0476	0.0151	0.0363	0.5738
<i>Dea</i>	数据要素应用能力	21056	3.6396	1.6325	0	7.5715
<i>Breadth</i>	数据要素广度应用能力	21056	2.6827	1.7029	0	7.5016
<i>Depth</i>	数据要素深度应用能力	21056	2.9145	1.6192	0	7.4079
<i>Age</i>	企业年龄	21056	2.9666	0.3098	1.3863	4.2195
<i>klr</i>	资本密集度	21056	0.6999	0.6099	-2.4288	5.7369
<i>Size</i>	企业规模	21056	7.5588	1.1575	3.5835	13.4638
<i>Bsize</i>	董事会规模	21056	2.2093	0.1713	1.6094	2.9444
<i>Dual</i>	两职合一	21056	0.3520	0.4776	0	1
<i>Debt</i>	经营负债	21056	0.1430	0.1048	0	0.7257
<i>Rd</i>	研发投入占比	21056	17.9992	1.4635	0	24.4101
<i>Indrate</i>	独立董事比例	21056	0.3777	0.0549	0.1667	0.7500
<i>Own</i>	股权制衡度	21056	0.8332	0.6323	0.0045	3.9218
<i>Lev</i>	资产负债率	21056	0.3978	0.2005	0.0080	1.9566

附录 5 内生性检验结果

附表 6 列（1）至列（6）汇报了工具变量两阶段最小二乘法的估计结果。实证结果显示，第一阶段中，地区雷电小时数（*IV*）的系数均在 1%的水平上显著为负，说明该工具变量与企业数据要素应用能力呈负相关，符合理论预期。在第二阶段中，企业数据要素应用能力（*Dea*）、数据要素广度应用能力（*Breadth*）和深度应用能力（*Depth*）的回归系数均显著为正，且深度应用能力（*Depth*）的回归系数显著高于广度应用能力（*Breadth*），说明在控制内生性问题后，企业增强数据要素深度应用能力对提升供应链韧性的作用更加突出。统计量检验结果进一步表明，地区雷电小时数（*IV*）通过了弱工具变量检验和不可识别检验，验证了工具变量设定的有效性。

附表 6 内生性检验：工具变量回归

变量	第一阶段	第二阶段	第一阶段	第二阶段	第一阶段	第二阶段
	(1) <i>Dea</i>	(2) <i>Res</i>	(3) <i>Breadth</i>	(4) <i>Res</i>	(5) <i>Depth</i>	(6) <i>Res</i>
<i>IV</i>	-0.0181*** (0.0051)		-0.0161*** (0.0035)		-0.0150*** (0.0049)	
<i>Dea</i>		0.0056* (0.0031)				
<i>Breadth</i>				0.0063* (0.0035)		
<i>Depth</i>						0.0067* (0.0039)
控制变量	是	是	是	是	是	是
企业固定效应	是	是	是	是	是	是
年份固定效应	是	是	是	是	是	是
样本数	16384	16384	16384	16384	16384	16384
Cragg-Donald Wald F statistic	35.986***		39.646***		25.651***	
Cragg-Donald Wald F statistic	97.314 [16.38]		70.991 [16.38]		56.503 [16.38]	

注：[]内为 Stock-Yogo 弱工具变量识别 F 检验在 10%的显著性水平上的临界值。

附录6 稳健性检验结果

（1）倾向得分匹配法。本文选择倾向得分匹配法（PSM）进行稳健性检验。具体而言，分别根据企业数据要素应用能力（*Dea*）、数据要素广度应用能力（*Breadth*）和深度应用能力（*Depth*）的年度中位数划分为高低两组，并利用上述控制变量作为配比的协变量，按照核匹配法进行样本匹配。附表7汇报了倾向得分匹配后的回归结果，估计结果与上述结论一致。

附表7 稳健性检验：倾向得分匹配回归

变量	(1)	(2)	(3)
<i>Dea</i>	0.0018*** (0.0004)		
<i>Breadth</i>		0.0004* (0.0002)	
<i>Depth</i>			0.0019*** (0.0004)
控制变量	是	是	是
企业固定效应	是	是	是
年份固定效应	是	是	是
样本数	20619	20597	20618
R ²	0.4838	0.4769	0.4670

（2）替换变量衡量方式。本文通过替换核心解释变量企业数据要素应用能力（*Dea*）和被解释变量供应链韧性（*Res*）的衡量方式来进一步保证上述研究结论的稳健性。首先，为消除年报文本篇幅差异可能带来的影响，本文将企业数据要素应用能力（*Dea*）、数据要素广度应用能力（*Breadth*）和数据要素深度应用能力（*Depth*）的词频数与年报总词频数的比值乘以1000^①（即 *Dea_count*、*Breadth_count*、*Depth_count*），以此重新衡量核心解释变量。附表7中列（1）至列（3）的回归结果显示，*Dea_count*、*Breadth_count*、*Depth_count*的系数在显著性及方向上均与前文保持一致。其次，在替换被解释变量方面，本文借鉴Modi and Mabert（2010）的思路，以营业成本与存货净额平均余额之比衡量企业库存周转率，并取其对数得到指标*Res1*，以此替代供应链韧性变量并重新进行回归。附表8列（4）至（6）汇报了替换被解释变量衡量方式后的回归结果，核心解释变量的系数方向与显著性水平依然与上述结论一致。

^① 需要说明的是，原有的比值较小，直接应用可能导致在回归过程中难以有效识别其对结果的影响，且可能被其他较大特征的影响所掩盖，从而使模型忽视该特征的信息。因此，通过放大比值可以增强该特征的代表性和稳定性，提高其在模型中的可识别性和贡献度。

附表 8 稳健性检验：替换变量衡量方式

变量	(1) <i>Res</i>	(2) <i>Res</i>	(3) <i>Res</i>	(4) <i>ResI</i>	(5) <i>ResI</i>	(6) <i>ResI</i>
<i>Dea_count</i>	0.0086*** (0.0018)					
<i>Breadth_count</i>		0.0049* (0.0025)				
<i>Depth_count</i>			0.0145*** (0.0027)			
<i>Dea</i>				0.0680*** (0.0131)		
<i>Breadth</i>					0.0170** (0.0076)	
<i>Depth</i>						0.0804*** (0.0138)
控制变量	是	是	是	是	是	是
企业固定效应	是	是	是	是	是	是
年份固定效应	是	是	是	是	是	是
样本数	20621	20621	20621	20621	20621	20621
R ²	0.4199	0.4061	0.4255	0.8372	0.8361	0.8379

(3) 更换估计方法。为了解决样本数据中存在的分布偏态、异方差以及计数型特征所带来的局限性，本文采用 PPML (Poisson Pseudo-Maximum Likelihood) 模型重新进行估计，以提升结论的稳健性与可靠性。PPML 基于伪最大似然的回归估计原理，能够在数据存在过度离散或异方差的情况下提供一致且有效的参数估计。与传统泊松回归不同，PPML 不要求因变量严格服从泊松分布，而是通过伪似然函数优化实现对非均匀方差的稳健处理。附表 9 报告的 PPML 的回归估计结果显示，企业数据要素应用能力 (*Dea*)、数据要素广度应用能力 (*Breadth*) 和深度应用能力 (*Depth*) 的回归系数依然显著为正，且深度应用能力 (*Depth*) 的回归系数显著高于广度应用能力 (*Breadth*)，结果与基准回归保持一致。

附表 9 稳健性检验：更换估计方法


变量	(1)	(2)	(3)
<i>Dea</i>	0.0327*** (0.0056)		
<i>Breadth</i>		0.0093** (0.0041)	
<i>Depth</i>			0.0367*** (0.0054)
控制变量	是	是	是
企业固定效应	是	是	是
年份固定效应	是	是	是
样本数	20621	20621	20621
R ²	0.0048	0.0048	0.0048

(4) 调整固定效应。尽管本文充分控制了年份和企业层面的固定效应，但仍可能存在不同行业在特定年份受到的共同冲击。为进一步缓解这一潜在影响，本文在模型中加入行业与年份的联合固定效应，回归结果如附表 10 所示。引入联合固定效应后，企业数据要素应用能力 (*Dea*)、数据要素广度应用能力 (*Breadth*) 和深度应用能力 (*Depth*) 的回归系数依然显著为正，与上述结论一致。


附表 10 稳健性检验：调整固定效应

变量	(1)	(2)	(3)
<i>Dea</i>	0.0014*** (0.0002)		
<i>Breadth</i>		0.0005** (0.0002)	
<i>Depth</i>			0.0015*** (0.0002)
控制变量	是	是	是
企业固定效应	是	是	是
年份固定效应	是	是	是
行业与年份联合固定效应	是	是	是
样本数	20474	20474	20474
R ²	0.4668	0.4646	0.4678


（5）安慰剂检验。为进一步验证核心解释变量的效应是否受随机因素驱动，本文采用安慰剂检验方法进行稳健性检验。若企业数据要素应用能力确实能够有效增强供应链韧性，则随机打乱相关变量与因变量匹配关系后，其影响应显著减弱或消失；反之，若随机扰动后仍出现与基准结果相近的估计值，则可能意味着基准结果仅由随机因素造成。基于此，本文将三个核心解释变量分别进行有放回的随机抽样，并重复进行 5000 次回归以记录每次估计系数。安慰剂检验结果显示，真实系数均位于安慰剂模拟系数分布的极端边界之外，表明随机扰动难以生成与基准回归同等强度的估计结果，从而排除了结果由随机误差引致的可能性。



附图 4 安慰剂检验：数据要素应用能力



附图 5 安慰剂检验：数据要素广度应用能力



附图 6 安慰剂检验：数据要素深度应用能力

（6）排除相关政策干扰。为控制相关政策试点对上述回归结果的干扰，本文在稳健性检验中剔除了与核心变量密切相关的政策地区与企业。具体包括：①全国供应链创新与应

用示范城市和示范企业。该试点旨在培育供应链优势、提升供应链效率与安全稳定水平，强化区域和企业 在供应链协同与风险管控方面的能力。因此，供应链韧性的提升可能部分源于政策扶持，而非企业自身数据要素应用能力增强的结果。②智能建造城市试点。该试点显著改善了企业外部数据环境，增强了数据要素可获得性与应用场景丰富度，可能外生性地提高企业的数据要素应用能力。为控制上述潜在偏差，本文剔除了相关城市和企业样本并重新进行回归。附表 11 列（1）至列（6）报告了排除全国供应链创新与应用示范城市、示范企业和智能建造城市试点后的回归结果。结果显示，核心解释变量的系数方向与显著性均与前文一致，进一步验证了研究结论的稳健性。

附表 11 稳健性检验：排除相关政策试点干扰

变量	排除全国供应链创新与应用示范城市和示范企业			排除智能建造城市试点		
	(1)	(2)	(3)	(4)	(5)	(6)
<i>Dea</i>	0.0016*** (0.0003)			0.0017*** (0.0003)		
<i>Breadth</i>		0.0004* (0.0002)			0.0004* (0.0002)	
<i>Depth</i>			0.0018*** (0.0003)			0.0019*** (0.0003)
控制变量	是	是	是	是	是	是
企业固定效应	是	是	是	是	是	是
年份固定效应	是	是	是	是	是	是
样本数	19215	19215	19215	17824	17824	17824
R ²	0.4055	0.4020	0.4074	0.4257	0.4221	0.4280

（6）双重机器学习方法。为缓解传统线性回归模型在高维控制变量情形下面临的模型设定偏误与“高维诅咒”等问题，本文进一步借鉴 Chernozhukov et al.（2018）提出的双重机器学习方法，对基准回归进行再估计。具体地，本文将样本随机划分为训练集与验证集，分割比例设定为 1:4，并分别采用支持向量机（SVM）、套索回归（LassoCV）、随机森林（RF）和梯度提升（GradBoost）等多种机器学习算法，对处理效应和高维控制变量之间的关系进行灵活拟合，从而获取双重机器学习估计量。相应回归结果见附表 12 的 Panel A。作为稳健性检验，Panel B 在采用相同算法组合的基础上，将样本分割比例调整为 1:5 重新估计。整体来看，双重机器学习方法得到的估计结果与基准回归结论基本一致。

附表 12 稳健性检验：双重机器学习回归


Panel A: 1:4 样本分割比例下的双重机器学习回归检验									
变量	SVM	SVM	SVM	LassoCV	LassoCV	LassoCV	GradBoost	GradBoost	GradBoost
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
<i>Dea</i>	0.0006*** (0.0001)			0.0015*** (0.0002)			0.0006*** (0.0001)		
<i>Breadth</i>		0.0002*** (0.0001)			0.0004*** (0.0001)			0.0002** (0.0001)	
<i>Depth</i>			0.0008*** (0.0001)			0.0018*** (0.0003)			0.0008*** (0.0001)
控制变量一次项	是	是	是	是	是	是	是	是	是
控制变量二次项	是	是	是	是	是	是	是	是	是
企业/年份固定效应	是	是	是	是	是	是	是	是	是
样本数	21056	21056	21056	21056	21056	21056	21056	21056	21056
Panel B: 1:5 样本分割比例下的双重机器学习回归检验									
变量	(10)	(11)	(12)	(13)	(14)	(15)	(16)	(17)	(18)
<i>Dea</i>	0.0006*** (0.0001)			0.0014*** (0.0002)			0.0006** (0.0001)		
<i>Breadth</i>		0.0002*** (0.0001)			0.0004*** (0.0001)			0.0002** (0.0001)	
<i>Depth</i>			0.0008*** (0.0001)			0.0017*** (0.0002)			0.0008*** (0.0001)
<i>Constant</i>	-0.0894*** (0.0001)	-0.0894*** (0.0001)	-0.0894*** (0.0001)	0.0000 (0.0001)	0.0000 (0.0001)	0.0000 (0.0001)	0.0001 (0.0001)	0.0001 (0.0001)	0.0001 (0.0001)
控制变量一次项	是	是	是	是	是	是	是	是	是
控制变量二次项	是	是	是	是	是	是	是	是	是
企业/年份固定效应	是	是	是	是	是	是	是	是	是
样本数	21056	21056	21056	21056	21056	21056	21056	21056	21056

附录 7 数商生态发展水平指标测度过程

本文基于全国工商企业数据库中 2.5 亿余条企业记录，运用多重文本挖掘与机器学习方法，系统识别各地新增数据商企业数量。首先，提取企业名称、注册城市、成立年份、所属行业、经营范围等关键信息，并通过正则化处理和文本标准化技术进行数据清洗，确保基础文本数据的规范性与可用性。其次，依据《全国数商产业发展报告（2023）》对数据商的界定，构建覆盖数据采集、数据治理、数据资产、数据交易、人工智能、云计算、信息服务等高频业务关键词的专业词典，综合运用关键词匹配、模糊匹配、语义相似度计算和规则过滤等互补性识别策略，以兼顾识别结果的准确性与全面性。具体做法为，先通过精确关键词匹配快速筛选典型数据商，再借助模糊匹配技术对经营范围文本进行比对，识别潜在相关业务，结合企业名称与所属行业的特征词进一步筛选疑似数据商，并最终运用 TF-IDF 向量化与余弦相似度算法度量经营范围与关键词集合的语义接近度，以提高识别的稳健性。最后，在多层次识别结果的基础上，对企业是否具备数据商属性进行综合判定，并按城市和年份统计新增数据商数量，从而构建城市层面的数商生态发展指标。


附录 8 动态需求趋势图示

假设企业产品质量或创新水平为 G ，当 G 保持不变时，按照传统理论，单个客户在重复消费过程中通常会呈现边际效用递减；但当企业不断应用数据要素优化产品设计与服务体验时，客户感知效用会在若干关键时间点出现阶段性跃升，形成“跳跃式”的边际效用动态递增趋势，如附图 7 所示。对于处于供应链网络关键位置的企业而言，这种基于数据形成的效用跃迁不再局限于个别交易关系，而是可以借助其与多节点之间的紧密连接在网络中加速扩散。随着数据共享与协同学习机制的运行，不同节点对需求和供给冲击的识别、吸收与调整能力被同步提升，使整体需求曲线在不同质量或创新水平 G_1 、 G_2 、 G_3 下不断向右上方移动，呈现出附图 8 所示的动态增长态势。由此可以认为，在供应链网络中，处于关键位置的企业更易通过增强数据要素应用能力实现跨节点联动，其对供应链韧性的强化效应也更加突出。



附图 7：企业增强数据要素应用能力引致客户边际效用的“跳跃式”动态递增^①

^① 在客户边际效用递减区域如（ Q_1 到 Q_2 ）会受到数据技术应用的影响，当数据技术进步时，改进 G 的速度越快，那么边际递减区域越小；当速度趋于无穷大时，边际效用递减区域会收敛为一个点，此时数据要素决定的动态需求趋势将演变为一连续的需求曲线。



附图 8：企业增强数据要素应用能力导致向右上倾斜的动态需求趋势

参考文献

- [1] 钞小静, 薛志欣. 新型信息基础设施对中国经济韧性的影响——来自中国城市的经验证据[J]. 经济学动态, 2023, (08): 44-62.
- [2] 冯启良, 安琪, 方炜. 数字技术赋能中国高技术制造企业关键核心技术创新的影响研究[J]. 管理学报, 2025, (4): 690-699.
- [3] 金星晔, 左从江, 方明月, 李涛, 聂辉华. 企业数字化转型的测度难题: 基于大语言模型的新方法与新发现[J]. 经济研究, 2024, (3): 34-53.
- [4] 李玉花, 林雨昕, 李丹丹. 人工智能技术应用如何影响企业创新[J]. 中国工业经济, 2024, (10): 155-173.
- [5] 乔晗, 李卓伦. 数据要素市场化配置效率评价研究[J]. 中国科学院院刊, 2022, (10): 1444-1456.
- [6] 孙新波, 钱雨, 张明超, 李金柱. 大数据驱动企业供应链敏捷性的实现机理研究[J]. 管理世界, 2019, 35(09): 133-151+200.
- [7] 王海, 闫卓毓, 郭冠宇, 等. 数字基础设施政策与企业数字化转型: “赋能”还是“负能”? [J]. 数量经济技术经济研究, 2023, 40(05): 5-23.
- [8] Chernozhukov, V., D. Chetverikov, M. Demirer, E. Duflo, C. Hansen, W. Newey, and J. Robins. Double/Debiased Machine Learning for Treatment and Structural Parameters[J]. The Econometrics Journal, 2018, 21(1): 1-68.
- [9] Cockburn, I. M., R. Henderson, and S. Stern. The Impact of Artificial Intelligence on Innovation: An Exploratory Analysis[M]//The Economics of Artificial Intelligence: An Agenda. University of Chicago Press, 2018: 115-146.
- [10] Eisfeldt, A. L., G. Schubert, M. B. Zhang, and B. Taska. The Labor Impact of Generative AI on Firm Values[R]. Available at SSRN, 2024, 4436627.
- [11] Modi, S. B., and V. A. Mabert. Exploring the Relationship between Efficient Supply Chain Management and Firm Innovation: An Archival Search and Analysis[J]. Journal of Supply Chain Management, 2010, 46(4): 81-94.

注：该附录是期刊所发表论文的组成部分，同样视为作者公开发表的内容。如研究中使用该附录中的内容，请务必在研究成果上注明引文和下载附件出处。

引用示例：

参考文献引用范例：

[1] 朱军. 技术吸收、政府推动与中国全要素生产率提升[J]. 中国工业经济. 2017, (1):5-24.

如果研究中使用了未在《中国工业经济》纸质版刊发、但在杂志网站上正式公开发表的数字内容（包括数据、程序、附录文件），请务必在研究成果正文中注明：

数据（及程序等附件）来自朱军（2017），参见在《中国工业经济》网站（<https://ciejournal.ajcass.com>）附件下载。